

Aula 2: Build, Tell, Connect

/ Cases, storytelling, projetos e os primeiros passos em MCP.

Prof. Ioannis Eleftheriou






"Nenhuma boa ação sairá impune"

IOANNIS PEDRO ELEFThERIOU



 /ioannispedroeleftheriou

- Level: 31
- Classe: Engenheiro de IA, professor nas disciplinas Engenharia de Machine Learning e AI Scientist na FIAP.
- Subclasse: MBA em Data Science pela FIAP e Bacharel em Game Design
- Analista Arcano: Mais de 10 anos de experiência com Crédito e Dados
- Empresas que atuei: HSBC, Bradesco, Vortex, Itaú, Grupo Boticário
- Criador de universos visuais e narrativas que tornam o conhecimento acessível e inspirador — da lousa ao código.



No fundo, sou apenas um cara que gosta de aprender e dividir conhecimento...



E acredito que o papel da IA é expandir nossas capacidades e não limitá-las.

Agenda da Semana 1



Panorama do
Ecossistema
Moderno de Agentes

14/09



Mentoria 1
Definição do Projeto
(Obrigatória)

Opt 1 - 16/09

Opt 2 - 23/09

Opt 3 - 30/09



Cases,
Ferramentas para
a vida, indicações
de leitura e
aprofundamento
técnico

O que veremos hoje



Projeto: BV Assist



Cases



7 Tools for Life



MCP I:
Primeiros
passos



/ Problema de Negócio:

BV Assist





“Simple is better than **complex**”

Fonte: https://openbookproject.net/books/bpp4awd/_static/ch10/zen.html

Tim Peters at Pycon 2004 (8/22/04)

/ Ideias de copiloto

Copiloto de Onboarding e RH Interno

Assistente para apoiar novos colaboradores nos primeiros 90 dias. Responde dúvidas sobre benefícios, trilhas obrigatórias, acesso a sistemas e políticas de trabalho híbrido, além de abrir solicitações de onboarding para RH e TI. É um ótimo exercício para praticar consulta de base documental + execução de ações com aprovação humana em casos sensíveis.

Copiloto de Incidentes Operacionais de TI

Assistente para times de suporte e operações durante incidentes. Ele classifica severidade, consulta runbooks internos, sugere procedimentos de contenção e cria/atualiza chamados no service desk com rastreabilidade completa. É uma temática forte para treinar fluxo multiagente, guardrails de segurança e observabilidade ponta a ponta.

/ Ideias de copiloto

Copiloto de Crédito e Formalização

Apoia analistas na jornada de crédito PJ/PF: consulta políticas internas de aprovação, valida documentação mínima por produto, sinaliza pendências e abre solicitação de revisão para mesa de crédito.

Valor didático: regras de negócio, decisões com aprovação humana em casos críticos e trilha de auditoria.

Copiloto de Fraude e Segurança Transacional

Ajuda times de prevenção a fraude a classificar alertas, consultar playbooks internos, sugerir ações de contenção (bloqueio temporário, escalonamento, contato com cliente) e registrar incidente no sistema interno.

Valor didático: guardrails fortes, fluxo multiagente (triagem-investigação-auditoria) e observabilidade detalhada.

O que é a Entrega esperada?



O que todos devem
conseguir entregar.

Um business case com
uma dor real do BV

ou

Um dos exercícios
propostos.



O que seria bem
legal de vermos no
final do curso


Um workflow MVP funcional em ambiente
local com Business Case de uma dor do BV
ou produto idealizado.


ou

MVP com deploy em cloud gratuita como
Render ou até mesmo deploy interno no BV



/ Cases





/ JPMorgan Chase

- Da pesquisa manual à precisão impulsionada por IA.
- Ask David é um sistema multiagente, orquestrado por um supervisor.
- Converte consultas NL em chamadas SQL ou de API.
- Gera resumos concisos por meio do LLM



/ Contaí Reporter

- MVP de sistema multi agentes para registro e documentação de eventos
- Utilizando FastAPI + LangGraph e CrewAI com sistema multiagente, orquestrado por um supervisor.
- Converte texto livre em artigos jornalísticos e popula registro de eventos no banco de matérias

[Voltar ao Início](#)

PROCESSAMENTO DE EVENTOS

Sistema inteligente de análise e geração de matérias jornalísticas



Análise do Evento

Extração automática de dados estruturados

ATIVA

DESCRIÇÃO DO EVENTO:

Cole aqui a descrição completa do evento...

Exemplo:
Workshop de FastAPI e SQLAlchemy
Data: 20 de setembro de 2024 às 19:00
Local: Av. Paulista, 1000 - São Paulo/SP
Organizador: Python São Paulo
Preço: Gratuito

[Analisar Evento com IA](#)



Dados Extraídos pela IA

Revisão e complementação de informações

PENDENTE



Aguardando análise

Os dados extraídos aparecerão aqui após a análise do evento



Matéria Jornalística

Geração automática de artigo profissional

PENDENTE

[Voltar ao Início](#)

EVENTOS CADASTRADOS

Biblioteca completa de eventos processados pelo sistema

[+ Novo Evento](#)

☰



COMPLETO

Evento Teste Do Deploy

Data: 2023-09-17
Local: estúdio XTL avenida franz woegeli
Organizador: luanna Eleftheriou

[Ver Detalhes](#)



1

TOTAL DE EVENTOS



1

COMPLETOS



0

PENDENTES



Visão geral

NyxGPT


Execuções

Modelos

Benchmarking

Máquina

Configurações



COMPUTE CORE

Sua máquina. Trabalho compartilhado.

Os produtos pedem. O Compute organiza a execução.

0

em execução

0

na fila

1

modelos residentes

MÁQUINA FÍSICA

NVIDIA GeForce RTX 5090 Laptop GPU

[Ver escopos →](#)

GPU em atividade

11 %

Observado · nvidia-smi
07:24:31

Temperatura da GPU

64 °C

Observado · nvidia-smi
07:24:31

Potência da GPU

27,9 W

Observado · nvidia-smi
07:24:31

VRAM ocupada

16.024 MiB

Observado · nvidia-smi:continuous
07:24:33

Memória da GPU

15,6 / 23,9 GiB

Ocupação observado · workstation-host · 07:24:33

Margem operacional

4 GiB

Reservas em preparação

0 GiB

Leases ativas

0 GiB

Ocupação não atribuída

Medição insuficiente

Reservas são compromissos de execução. Leases ativas podem já estar incluídas na ocupação observada.

+ Nova conversa

Buscar conversas

SUAS CONVERSAS

Explique um conceito passo a p...

oi

quem somos nós?

oi

Qual é o orçamento aprovado ...

Qual é o orçamento aprovado ...

Explique cinco passos para org...

não entendi nada.

oi

Nova conversa

Ensaio técnico do chat: em até ...

← Compute Center

Aparência

Escura

NyxGPT gpt-oss:20b

MCP (Micro-Controlador Protocolo) vs A2A (Application-to-Application)

Etapa	MCP	A2A
1. Definição	Protocolo de comunicação interno entre dispositivos microcontroladores (ex: I²C, SPI, UART).	Arquitetura de comunicação entre aplicações (softwares) em sistemas distribuídos (ex: REST, gRPC, AMQP).
2. Camada de atuação	Camada física/ligação de dados (nível baixo).	Camada de aplicação (nível alto).
3. Responsabilidade principal	Troca de bytes, sincronização de clock, endereçamento de dispositivos.	Troca de mensagens estruturadas, definição de APIs, contrato de dados entre serviços.
4. Complexidade de implementação	Relativamente simples: portas de E/S, interrupções, buffers.	Mais complexa: serialização/deserialização, autenticação, gerenciamento de sessões.
5. Escopo de comunicação	Entre microcontroladores dentro de um mesmo circuito ou placa.	Entre máquinas ou processos que podem estar em redes locais ou globais.
6. Exemplo típico de uso	Sensores, atuadores, displays ligados a um MCU.	Sistemas de micro-serviços, integração de ERP com CRM.
7. Ferramentas comuns	IDEs de MCU (Keil, MPLAB), simuladores de bus.	SDKs de APIs (OpenAPI), frameworks de mensageria (RabbitMQ).
8. Segurança	Principalmente físico (circuito).	Criptografia, tokens, controle de acesso.
9. Escalabilidade	Limitada ao número de dispositivos no bus.	Altamente escalável: pode ser distribuído globalmente.
10. Testes	Testes de hardware (osciloscópio, analisador lógico).	Testes de contrato, mocks de API, testes de carga.

Resumo rápido

- **MCP:** protocolo de comunicação de nível baixo entre microcontroladores dentro de um circuito.

Converse com o NyxGPT...

+ Anexar


Local - seus dados ficam aqui

Enviar ↑


Percurso desta execução

Último evento

Reconstrução dos eventos registrados. A máquina ao vivo continua abaixo.



Percorrer o histórico



Concluída 18/09/2026, 07:24:17 +224,78 s desde o primeiro evento




Tempos de fila e execução são derivados do ledger. Este percurso não reconstrói a ocupação histórica de RAM ou GPU.

Topologia de execução

- 100% + Enquadrar

Pedido → modelo residente → runtime → máquina. Pesos compartilhados aparecem uma vez.





/ 7 Ferramentas para Vida



#1 NEW YORK TIMES BESTSELLER

**BE USEFUL
SEVEN TOOLS FOR LIFE
ARNOLD
SCHWARZENEGGER**

/ Recomendação de leitura

Schwarzenegger, A. (2023). **Be Useful: Seven Tools for Life.** Penguin Press.

referência inspiracional sobre visão, disciplina e execução, trazendo sete ferramentas práticas para transformar ambição em projetos, carreira e impacto real.

/ Tenha uma Visão Clara



Antes de construir, enxergue a **direção**.



Visão é o que transforma estudo solto em trilha.



Projeto sem visão, vira uma **tarefa sem alma**.

/ Nunca Pense Pequeno

Realismo demais pode ser **medo**
disfarçado.

Comece pequeno, mas pense em
escala.

O tamanho atual não **define o futuro.**



“There’s no fate but what we make for
ourselves”

/ Trabalhe Duro

Nenhuma ferramenta substitui
consistência.

O aprendizado nasce da repetição e
do atrito.

Ideia sem execução é só desejo.




/ Sell, Sell, Sell.

Vender é comunicar valor.

Excelência invisível não gera impacto.

Toda boa solução precisa de narrativa.



/ Mude de marcha.

Persistir não é insistir no caminho
errado.

Ajustar rota também é estratégia.

O plano precisa sobreviver à realidade.

Nenhum plano sobrevive intacto à realidade.
Persistência não é teimosia; o erro é ignorar
os sinais.




/ Cale a boca e abra a mente.

Crescer exige **escutar** antes de responder.

Feedback é desconfortável, mas necessário.

A realidade precisa editar suas **certezas**.



/ Quebre seus espelhos.

Pare de olhar só para si.

Ser útil é resolver problemas reais.

Impacto nasce quando o ego sai do
centro.





Fonte da imagem: Autor recriação.

/ Uma solução robusta, sobrevive e se adapta ao tempo

Documente, compartilhe conhecimento e tenha sempre um plano de governança e manutenção. Sem essa disciplina, até soluções brilhantes ficam obsoletas em pouco tempo.

A inteligência está no processo, não no modelo.



/ INTERVALO :)






/ Qual a diferença entre MCP
e RAG?



/ Chat genérico vs Extração estruturada

Modelos de linguagem são **gerativos, não determinísticos**, então a mesma pergunta raramente vem exatamente igual duas vezes.

Em **extração estruturada**, ao invés de uma resposta em texto livre, buscamos que a IA produza dados em um formato **padronizado e previsível**.



/ RAG

Retrieval-Augmented Generation

R - Retrieve: Encontra informações úteis

A - Augment: Adiciona elas ao conhecimento da IA


G - Generate: Gera uma resposta mais eficiente.

/ RAG

Retrieval-Augmented Generation

RAG é dar ao modelo uma “cola” confiável: antes de gerar a resposta, ele busca informações relevantes em uma base de conhecimento fornecida, e usa isso de contexto

Em **extração estruturada**, ao invés de uma resposta em texto livre, buscamos que a IA produza dados em um formato **padronizado e previsível**.




Fonte da imagem: Autor, Nano Banana.

/ RAG

Retrieval-Augmented Generation

Parallel
distributed
discovery






/ E MCP?



/ Para que serve o MCP

Não derrota Boss mas blinda a organização

MCP: O 'USB-C' das Inteligências Artificiais



- Tools: Funções executáveis (somar, buscar)
- Resources: Dados passivos (Logs, PDFs)
- Prompts: Templates pré-definidos


/ Fluxo de Arquitetura

HOST Interface do usuário que decide a experiência e aprovação.

Client Componente que mantém a conexão protocolar dedicada.


Server Servidor que expõe o contexto e as capacidades sistêmicas

Arquitetura MCP: Cliente e Servidor



O LLM só acessa o que é explicitamente exposto. JetBrains Mono

/ Para que serve o MCP



/ As primitivas centrais

Prompt são templates reutilizáveis e parametrizáveis. Eles são pensados para exposição user-controlled, normalmente acionados por slash commands, menus ou UX explícita.

“Como eu quero conduzir esta interação?”

Resources são dados contextualizáveis identificados por URI. A especificação os trata como application-driven, o que faz sentido: o cliente decide quando e como anexar contexto ao fluxo da aplicação. “Que contexto devo disponibilizar?”

Tools são capacidades executáveis. Elas são model-controlled no protocolo, embora a especificação recomende fortemente presença humana no loop para operações sensíveis. “Que ação posso executar agora?”

/ As primitivas centrais

0 Blueprint do Servidor Python (FastMCP)

```
from mcp.server.fastmcp import FastMCP
mcp = FastMCP('Políticas MCP')
```

```
@mcp.resource('policies://catalog')
def policies_catalog() -> str:
    """Catálogo em JSON."""
```

```
@mcp.tool()
def search_policies(query: str) -> str:
    """Busca políticas por título."""
```


```
if __name__ == '__main__':
    mcp.run(transport='streamable-http')
```

A URI define acesso estável para leitura (Sem side-effects).

Docstrings e Type Hints são automaticamente traduzidos para JSON Schema validado no transporte.

Transporte exposto via rede. O pacote 'mcp[cli]' permite o modo de produção HTTP em vez do frágil stdio.

/ As primitivas centrais



/ As primitivas centrais

Para adicionar
clientes e
dispositivos

Official MCP Registry

Discover Model Context Protocol servers

[GitHub](#) [Docs](#) [API Reference](#)

Recently Updated

co.heista/api v1.0.0
Decode video ads, load brand intelligence, generate ad scripts.
Updated 11/05/2026

io.github.TopoLift/topolift-mcp v0.2.1
Atom-grounded negotiation reasoning. Typed topology slot, inline citations, public dialect.
Updated 11/05/2026

io.github.safedep/vet-mcp v1.17.0
Protect your AI agents and IDEs from malicious open-source packages.
Updated 11/05/2026

io.github.whw23/searxng-http-mcp v2026.42.0
Self-contained SearXNG metasearch MCP server. One Docker image, 200+ engines, privacy-first.
Updated 11/05/2026

io.github.whw23/searxng-http-mcp v2026.43.0
Self-contained SearXNG metasearch MCP server. One Docker image, 200+ engines, privacy-first.
Updated 11/05/2026

☒ Show only latest versions

ac.inference.sh/mcp v1.0.1
Run 150+ AI apps — image, video, audio, LLMs, 3D and more. Browse, execute, stream results.
13/04/2026

Title: inference.sh
Status: Active
[View in API](#)
Remotes
streamable-http <https://sh.inference.ac>
streamable-http <https://api.inference.sh/mcp>
[► View full server.json](#)

ac.tandem/docs-mcp v0.3.2
Remote MCP server for Tandem docs, install guides, SDKs, workflows, and agent setup help.
22/02/2026

agency.lona/trading v2.0.0
AI-powered trading strategy development: backtesting, market data, and portfolio analysis
23/02/2026

ai.aarna/atars-mcp v0.1.0

ai.abmeter/abmeter v0.1.0


ai.adadvisor/mcp-server v1.0.1

/ JSON-RPC e transportes

stdio para integrações locais, em que o cliente dispara o servidor como subprocesso.

Streamable HTTP Componente que mantém a conexão protocolar dedicada.

HTTP+SSE apenas por compatibilidade retroativa, já tratado como legado na documentação.



Obrigado :)